

Trustworthy AI #2

▼ Problem 1 Differential Testing with DeepXplore

- Differential Testing : 동일한 입력을 여러 신경망에 입력하여 모델 간의 예측이 일치하지 않는 사례 Disagreement를 찾는 기법
- Neuron Coverage : 테스트 중 특정 임계값 이상으로 활성화된 뉴런의 비율
- DeepXplore : 신경망의 취약점을 찾아내기 위한 **자동화된 화이트박스 테스트 프레임워크**
 - 특정 임계값 이상으로 활성화된 뉴런의 비율을 최대화하는 방향으로 입력을 변형

▼ Experiments


▼ Settings

- chenyaofu/pytorch-cifar-models - cifar10_resnet56
- chenyaofu/pytorch-cifar-models - cifar10_resnet44
- CIFAR10 데이터셋 중 1,000개

▼ Results

```
Total Images Tested: 1000
Total Disagreement-inducing Inputs Found: 1000
Final Neuron Coverage: [tensor(0.3705), tensor(0.3845)]
```

- 테스트 샘플 1,000개 중, 불일치 Input이 1,000개 즉, 모든 입력 이미지에 대해 불일치가 발생
- 이는 DeepXplore가 두 모델의 예측 클래스가 달라지도록 perturbation을 성공적으로 생성
 - Differential Testing가 모델의 약점을 발견하는데 매우 강력한 도구임
- Neuron Coverage
 - **Model 1 (ResNet56): 37.05%**
 - **Model 2 (ResNet44): 38.45%**
 - 목적 함수를 통해 모델 내부 뉴런의 약 40% 가까이를 활성화함
- Image



- 동일한 이미지에 대해서 모델 1, 모델 2는 서로 다른 예측을 출력함

▼ Problem 2: Connecting Attacks and Testing

- FGSM, PGD와 DeepXplore는 모두 모델의 취약점을 노출한다는 공통된 목적을 가지고 있음.
특히 FGSM, PGD와 같은 공격을 통해 생성된 이미지는 Differential Testing의 이미지의 예제로 사용될 수 있음.
단순한 무작위 입력을 넣는 것이 아닌, 이미 모델에게 잘못된 분류를 야기 시킨 이미지는 모델 간의 불일치를 훨씬

빠르게 유도할 수 있고, Neuron Coverage는 Perturbation을 가할 타겟 뉴런을 선정하는 가이드라인을 수행할 수 있음.

- 두 기술을 결합하면 각각을 단독으로 사용할 때보다 더 적은 수의 입력으로 더 많은 오류를 발생시켜 효과적으로 모델의 취약점을 발견하는 것에 큰 도움이 될 수 있음.
- 다만, PGD와 같은 반복적인 공격 기법은 많은 연산량을 요구하고 있는데 DeepXplore와 같은 메커니즘이 합쳐졌을 때, 더욱 많은 컴퓨팅 자원과 시간이 요구 될 수 있음 또한, 다양한 기법이 처리된 이미지는 실제 환경에서 발생하지 않는 Noise로 변형되어 모델의 견고성에 도움이 되지 않을 수 있음.